



Cómputo Científico para Probabilidad, Estadística y Ciencia de Datos

Ezau Faridh Torres Torres

TAREA 6: MCMC: Metropolis-Hastings

Fecha de entrega: 16/Oct/2024.

NOTA: Los ejercicios se encuentran repartidos en los archivos:

- [ejercicio1_tarea6.py](#)
- [ejercicio2_tarea6.py](#)
- [ejercicio4_tarea6.py](#)

1. Simular $n = 5$ y $n = 50$ v.a's Bernoulli $Be(\frac{1}{3})$; sea r el número de éxitos en cada caso.

Respuesta:

En el archivo [ejercicio1_tarea6.py](#) se implementa la función `SIMULAR_BERNOULLI()` con la cual, se simulan $n = 5$ y $n = 50$ variables aleatorias Bernoulli $Be(\frac{1}{3})$ y se calcula el número de éxitos en cada caso. Se utiliza la función `np.random.binomial()` de la librería `numpy` para simular las variables aleatorias binomiales ya que para el caso de una sola prueba es equivalente a una distribución Bernoulli. Se obtuvieron los siguientes resultados (se usó una semilla para reproducibilidad):

- Éxitos para $n = 5$: 2.
- Éxitos para $n = 50$: 15.

2. Implementar el algoritmo Metropolis-Hastings para simular de la posterior.

$$f(p|\bar{x}) \propto p^r (1-p)^{n-r} \cos(\pi p) \cdot \mathbb{1}_{[0, \frac{1}{2}]}(p). \quad (1)$$

con los dos casos de n y r de arriba. Para ello poner la propuesta $(p'|p) = p' \sim \text{Beta}(r+1, n-r+1)$ y la distribución inicial de la cadena $\mu \sim \mathcal{U}(0, \frac{1}{2})$.

Respuesta:

En el archivo [ejercicio2_tarea6.py](#) se implementa la función `METROPOLIS_HASTINGS()`, la cual simula una cadena de Markov utilizando el algoritmo de Metropolis-Hastings y toma los siguientes argumentos:

- La función objetivo $f()$, (en este caso es la posterior (1)).
- La distribución propuesta $q()$ (en este caso es la distribución $\text{Beta}(r+1, n-r+1)$).
- El valor inicial x_0 (en este caso es $\mu \sim \mathcal{U}(0, \frac{1}{2})$).
- El número de iteraciones (por default se toma $N = 10000$).


Además, regresa la cadena de Markov simulada. Usa el criterio de aceptación: si y_t es la propuesta dada por $q(\cdot|x_t)$ en x_t , entonces se acepta y_t con probabilidad $\rho(x_t, y_t)$ con

$$\rho(x, y) = \min \left\{ 1, \frac{f(y) q(x|y)}{f(x) q(y|x)} \right\} \quad (2)$$

y se rechaza con probabilidad $1 - \rho(x_t, y_t)$. A continuaci  n, se define la funci  n posterior (1) llamada *posterior()*, y la funci  n *propuesta()* dada por $Beta(r + 1, n - r + 1)$ la cual, como vimos en clase, no depende del estado actual x_t .

Finalmente, se hizo la simulaci  n usando la funci  n la distribuci  n posterior (1) para $n = 5$ y $n = 50$ usando el algoritmo de Metropolis-Hastings haciendo uso de la funci  n *SIMULAR.BERNOULLI()* del ejercicio 1. Se comparan las distribuciones obtenidas con un histograma y se obtuvo el siguiente resultado para una muestra de tama  o $N = 10000$:

-   xitos para $n = 5$: 2.
-   xitos para $n = 50$: 15.



Podemos notar que en ambas simulaciones para n y r , se obtuvieron buenas estimaciones de $p = \frac{1}{3}$ ya que, $\frac{n}{r}$ no resulta tan alejado de $\frac{1}{3}$ para cada caso (se us   una semilla para reproducibilidad).

NOTA: Los comentarios extras se dan al final del ejercicio 3.

- Argumentar porque la cadena es f –irreducible y porque es erg  dica. Implementar el algoritmo con los datos descritos y discutir los resultados.

Respuesta:

Sabemos que la f –irreducibilidad de una cadena de Markov significa que es posible alcanzar cualquier subconjunto del espacio de estados a partir de cualquier estado con probabilidad positiva, donde f es una medida no trivial en el espacio de estados. En el contexto del

algoritmo Metropolis-Hastings con nuestra propuesta

$$p'|p \sim \text{Beta}(r+1, n-r+1), \quad (3)$$

la cadena es f -irreducible por las siguientes razones:

- **Soporte de la propuesta:** La distribución $\text{Beta}(r+1, n-r+1)$ tiene soporte en $[0, 1]$ (aunque la posterior tiene soporte restringido a $[0, \frac{1}{2}]$ y claramente $[0, \frac{1}{2}] \subset [0, 1]$). Esto significa que, desde cualquier valor $p \in (0, \frac{1}{2})$, la propuesta tiene probabilidad positiva de moverse a cualquier otro punto en este intervalo.
- **Aceptación de la propuesta:** La densidad objetivo $f(p|\bar{x})$ es continua y positiva en el intervalo $(0, \frac{1}{2})$ (aunque puede ser cercana a cero en los extremos). Esto asegura que hay una probabilidad positiva de aceptar cualquier propuesta $p'|p$ si proviene de la distribución $\text{Beta}(r+1, n-r+1)$, siempre que esté dentro de $(0, \frac{1}{2})$.

Por lo tanto, desde cualquier estado p , es posible alcanzar cualquier otro estado en $(0, \frac{1}{2})$ con probabilidad positiva, lo que asegura que la cadena es f -irreducible ■

Ahora, la ergodicidad de la cadena se refiere a que, con el tiempo, la cadena “visita” todos los estados posibles de manera que las frecuencias de visita convergen a las probabilidades estacionarias de la distribución objetivo $f(p|\bar{x})$. En clase revisamos que, el que la cadena sea f -irreducible entonces era ergódica, sin embargo, se va a detallar más:

La cadena es ergódica por las siguientes razones:

- **Irreducibilidad:** Ya se revisó que la cadena es f -irreducible, lo que es una condición necesaria para la ergodicidad.
- **Aperiodicidad:** La propuesta Beta no es determinista, lo que implica que no hay ciclos predefinidos en la cadena. Esto significa que la cadena no quedará atrapada en patrones cíclicos, y por tanto es aperiódica (en clase vimos que dada la aperiodicidad, la cadena convergía a la distribución objetivo).
- **Acotamiento del soporte:** La posterior (1) tiene soporte en $[0, \frac{1}{2}]$, lo que es un conjunto acotado. En este intervalo, la distribución Beta y la densidad objetivo permiten que la cadena se mueva de manera adecuada por todo el espacio, y la distribución $f(p|\bar{x})$ actúa como la distribución estacionaria ■

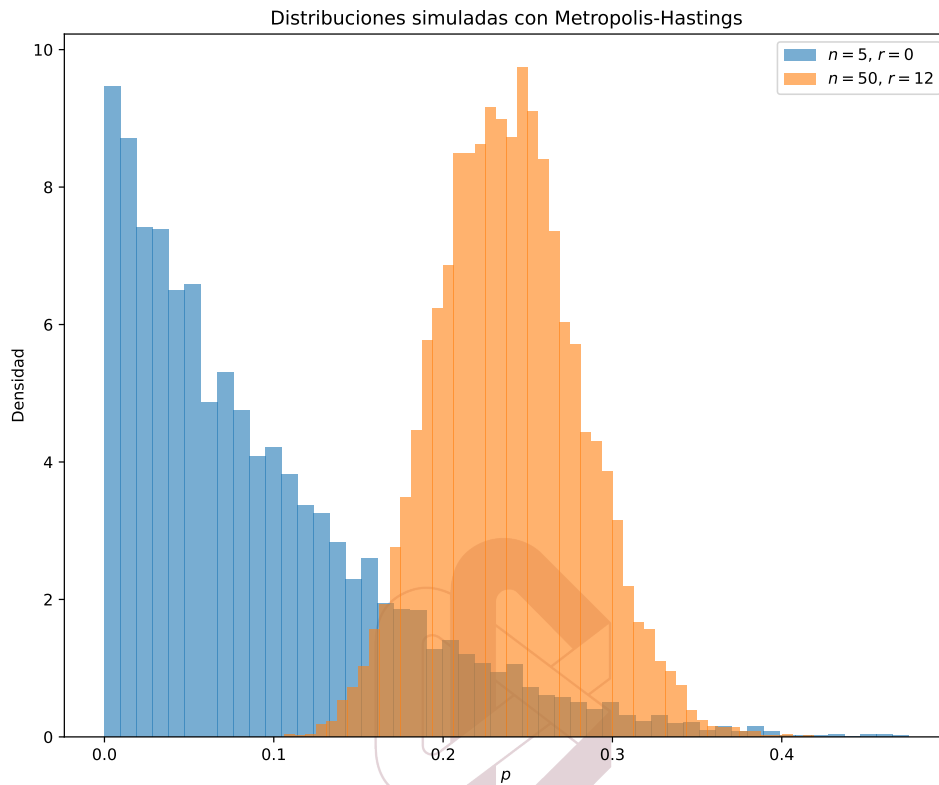
Resultados:

Ya se implementó el algoritmo con los datos descritos en el ejercicio anterior en el archivo [ejercicio2_tarea6.py](#) y se tienen los siguientes resultados/comentarios.

Como se mencionó antes, se puede notar que en ambas simulaciones para n y r , se obtuvieron buenas estimaciones de $p = \frac{1}{3}$ ya que, $\frac{n}{r}$ no resulta tan alejado de $\frac{1}{3}$ para cada caso. Variando la semilla, se notó en algunas ocasiones un mal desempeño al momento de estimar $p = \frac{1}{3}$, esto dependiente de la simulación de r para $n = 5$ o $n = 50$, ya que para ser un mejor estimador, r debe ser $\frac{n}{3}$ aproximadamente. Un ejemplo de esto se puede ver en la siguiente figura:

Además, cuando n es pequeño (como $n = 5$), la distribución simulada tiende a estar más dispersa. Esto se debe a que la cantidad de datos disponibles (5) no es suficiente para ajustar fuertemente los parámetros de la posterior. Cuando n es mayor, la distribución se ajusta más cerca de los valores que maximizan la posterior, lo que refleja una mayor precisión en la estimación del parámetro p debido a la mayor cantidad de datos.

Finalmente, dado que la cadena es erg  dica, tras un n  mero suficientemente grande de iteraciones, las muestras convergen a la distribuci  n posterior $f(p|\bar{x})$. Esto se observa en la forma de los histogramas que se alinean con las formas te  ricas esperadas de las distribuciones.



4. Implementar el algoritmo Metropolis-Hastings con la posterior de arriba tomando una propuesta diferente.

Respuesta:

Dentro de la bibliograf  a m  s importante relacionada con Metropolis-Hastings, se encontr   que un ejemplo com  n de propuesta es usar una distribuci  n normal sim  trica alrededor del valor actual p , como

$$p'|p \sim \mathcal{N}(p, \sigma^2), \quad (4)$$

truncada en el intervalo $[0, \frac{1}{2}]$. Esto garantiza que las propuestas siempre est  n dentro del dominio de la posterior. En el archivo [ejercicio4_tarea6.py](#) se usa la misma estructura del programa implementado en el ejercicio 2, con la diferencia de que se modific   la propuesta $(p'|p) = p' \sim \text{Beta}(r+1, n-r+1)$ por (4) con $\sigma^2 = 0.1$ para controlar la dispersi  n de las propuestas.

Se us   la misma distribuci  n inicial de la cadena $\mu \sim \mathcal{U}(0, \frac{1}{2})$ y se obtuvieron los siguientes resultados:

-   xitos para $n = 5$: 2.
-   xitos para $n = 50$: 15.

Además, experimentando con varias configuraciones, como variando el parámetro σ^2 y el número de muestras n , se pudo notar que, al igual que antes cuando n crece, se tiene que la distribución se ajusta más cerca de los valores que maximizan la posterior, lo que refleja una mayor precisión en la estimación del parámetro p debido a la mayor cantidad de datos y que funciona mejor con un valor de σ^2 pequeño. Se puede notar que la distribución propuesta (4), también cumple con las condiciones que hacen que la cadena sea f —irreducible y ergódica por las mismas razones mencionadas en el ejercicio 3.

